

Wielokryterialne planowanie produkcji w warunkach niepewności

WDWR 25406

12 kwietnia 2025

1 Analityczne sformułowanie modelu

1.1 Założenia modelu

Rozpatrujemy problem planowania produkcji w przedsiębiorstwie wytwarzającym 4 produkty (P1-P4) na 5 typach maszyn (szlifierki, wiertarki pionowe, wiertarki poziome, frezarki i tokarki) w perspektywie 3 miesięcy (styczeń, luty, marzec).

Podstawowe założenia modelu:

- Czas dostępny na każdej maszynie: $24 \text{ dni robocze} \times 8 \text{ godzin} \times 2 \text{ zmiany} = 384 \text{ godzin/miesiąc/maszynę}$
- Dochody ze sprzedaży są zmiennymi losowymi o rozkładzie t-Studenta (5 stopni swobody) ograniczonym do przedziału [5; 12]
- Obniżka dochodu o 20% przy sprzedaży przekraczającej 80% pojemności rynku
- Koszt magazynowania: 1 zł/sztukę/miesiąc
- Limit magazynowy: 200 sztuk każdego produktu
- Stan początkowy magazynu: 0 sztuk każdego produktu
- Pożądany stan końcowy: 50 sztuk każdego produktu na koniec marca

1.2 Podstawy teoretyczne

Model opiera się na następujących podstawach teoretycznych:

- **Programowanie liniowe** - do formułowania ograniczeń produkcyjnych i bilansów magazynowych
- **Optymalizacja wielokryterialna** - do modelowania kompromisu między zyskiem a ryzykiem

- **Programowanie stochastyczne** - do uwzględnienia niepewności dochodów ze sprzedaży
- **Dominacja stochastyczna** - do oceny relacji między różnymi rozwiązaniami efektywnymi
- **Różnica Giniego** - jako miara ryzyka oparta na odległościach między realizacjami

2 Specyfikacja problemu decyzyjnego

2.1 Zmienne decyzyjne

Definiujemy następujące zmienne decyzyjne:

- $x_{i,t}$ - liczba wyprodukowanych jednostek produktu i w miesiącu t
- $s_{i,t}$ - liczba sprzedanych jednostek produktu i w miesiącu t
- $inv_{i,t}$ - stan magazynowy produktu i na koniec miesiąca t
- $over_{i,t}$ - zmienna binarna określająca czy sprzedaż produktu i w miesiącu t przekracza 80% pojemności rynku

gdzie:

- $i \in \{1, 2, 3, 4\}$ - indeks produktu
- $t \in \{1, 2, 3\}$ - indeks miesiąca (1: styczeń, 2: luty, 3: marzec)

2.2 Ograniczenia

2.2.1 Ograniczenia czasowe maszyn

Dla każdego miesiąca $t \in \{1, 2, 3\}$:

1. Szlifierki (4 sztuki):

$$0.4 \cdot x_{1,t} + 0.6 \cdot x_{2,t} \leq 4 \cdot 384 = 1536 \text{ godzin} \quad (1)$$

2. Wiertarki pionowe (2 sztuki):

$$0.2 \cdot x_{1,t} + 0.1 \cdot x_{2,t} + 0.6 \cdot x_{4,t} \leq 2 \cdot 384 = 768 \text{ godzin} \quad (2)$$

3. Wiertarki poziome (3 sztuki):

$$0.1 \cdot x_{1,t} + 0.7 \cdot x_{3,t} \leq 3 \cdot 384 = 1152 \text{ godzin} \quad (3)$$

4. Frezarka (1 sztuka):

$$0.06 \cdot x_{1,t} + 0.04 \cdot x_{2,t} + 0.05 \cdot x_{4,t} \leq 1 \cdot 384 = 384 \text{ godzin} \quad (4)$$

5. Tokarka (1 sztuka):

$$0.05 \cdot x_{2,t} + 0.02 \cdot x_{3,t} \leq 1 \cdot 384 = 384 \text{ godzin} \quad (5)$$

2.2.2 Bilanse magazynowe

Dla każdego produktu $i \in \{1, 2, 3, 4\}$ i miesiąca $t \in \{1, 2, 3\}$:

$$inv_{i,t} = inv_{i,t-1} + x_{i,t} - s_{i,t} \quad (6)$$

Z warunkami początkowymi:

$$inv_{i,0} = 0 \text{ dla } i \in \{1, 2, 3, 4\} \quad (7)$$

I końcowymi:

$$inv_{i,3} = 50 \text{ dla } i \in \{1, 2, 3, 4\} \quad (8)$$

2.2.3 Ograniczenia rynkowe

Dla każdego produktu $i \in \{1, 2, 3, 4\}$ i miesiąca $t \in \{1, 2, 3\}$:

$$s_{i,t} \leq M_{i,t} \quad (9)$$

Gdzie $M_{i,t}$ to maksymalna liczba sztuk produktu i , którą może przyjąć rynek w miesiącu t (zgodnie z tabelą z zadania).

2.2.4 Ograniczenia pojemności magazynu

Dla każdego produktu $i \in \{1, 2, 3, 4\}$ i miesiąca $t \in \{1, 2, 3\}$:

$$inv_{i,t} \leq 200 \quad (10)$$

2.2.5 Ograniczenia dotyczące obniżki dochodu

Dla każdego produktu $i \in \{1, 2, 3, 4\}$ i miesiąca $t \in \{1, 2, 3\}$:

$$s_{i,t} \geq 0.8 \cdot M_{i,t} - M \cdot (1 - over_{i,t}) \quad (11)$$

$$s_{i,t} \leq 0.8 \cdot M_{i,t} + M \cdot over_{i,t} \quad (12)$$

Gdzie M to duża liczba (tzw. big-M).

2.2.6 Nieujemność zmiennych

$$x_{i,t}, s_{i,t}, inv_{i,t} \geq 0 \text{ dla } i \in \{1, 2, 3, 4\}, t \in \{1, 2, 3\} \quad (13)$$

2.3 Funkcje oceny

2.3.1 Oczekiwany zysk

$$E[Zysk] = \sum_{t=1}^3 \sum_{i=1}^4 E[R_i] \cdot s_{i,t} \cdot (1 - 0.2 \cdot over_{i,t}) - \sum_{t=1}^3 \sum_{i=1}^4 1 \cdot inv_{i,t} \quad (14)$$

Gdzie $E[R_i]$ to oczekiwany dochód ze sprzedaży jednostki produktu i , który należy wyznaczyć z rozkładu t-Studenta ograniczonego do przedziału $[5; 12]$ z parametrami μ i Σ .

2.3.2 Średnia różnica Giniego (miara ryzyka)

$$\Gamma(x) = \frac{1}{2} \sum_{t'=1}^T \sum_{t''=1}^T |r^{t'}(x) - r^{t''}(x)| \cdot p^{t'} \cdot p^{t''} \quad (15)$$

Gdzie:

- $r^t(x)$ - realizacja zysku w scenariuszu t dla decyzji x
- p^t - prawdopodobieństwo scenariusza t
- T - liczba rozważanych scenariuszy

3 Implementacja modelu

3.1 Środowisko implementacji

Do rozwiązania problemu wykorzystuję język R z bibliotekami:

- `lpSolveAPI` - do rozwiązania problemu optymalizacji liniowej
- `mvtnorm` - do generowania próbek z wielowymiarowego rozkładu t-Studenta
- `truncdist` - do implementacji rozkładu t-Studenta ograniczonego do przedziału [5; 12]
- `ggplot2` - do wizualizacji wyników

3.2 Kod źródłowy

```
1 # Biblioteki
2 library(lpSolveAPI)
3 library(mvtnorm)
4 library(ggplot2)
5
6 # Parametry problemu
7 set.seed(307585) # Numer zadania jako ziarno
8
9 # 1. Definicja danych śwejciovych
10 # -----
11 # Liczba produktów i ęmiesicy
12 n_products <- 4
13 n_months <- 3
14
15 # Czas produkcji (h/szt)
16 prod_time <- matrix(c(
17   0.4, 0.6, 0, 0,      # Szlifowanie
18   0.2, 0.1, 0, 0.6,    # Wiercenie pionowe
19   0.1, 0, 0.7, 0,      # Wiercenie poziome
20   0.06, 0.04, 0, 0.05, # Frezowanie
21   0, 0.05, 0.02, 0     # Toczenie
22 ), nrow = 5, byrow = TRUE)
```

```

23
24 # Liczba maszyn
25 n_machines <- c(4, 2, 3, 1, 1)
26
27 # Dostępny czas na maszyn na miesiąc (h)
28 time_per_machine <- 24 * 8 * 2 # 24 dni * 8h * 2 zmiany
29
30 # Ograniczenia rynkowe
31 market_limits <- matrix(c(
32   200, 0, 100, 200, # Styczeń
33   300, 100, 200, 200, # Luty
34   0, 300, 100, 200 # Marzec
35 ), nrow = 3, byrow = TRUE)
36
37 # Parametry rozkładu t-Studenta
38 mu <- c(9, 8, 7, 6)
39 Sigma <- matrix(c(
40   16, -2, -1, -3,
41   -2, 9, -4, -1,
42   -1, -4, 4, 1,
43   -3, -1, 1, 1
44 ), nrow = 4, byrow = TRUE)
45 df <- 5 # Stopnie swobody
46
47 # 2. Generowanie scenariuszy dla dochodów
48 # -----
49 n_scenarios <- 1000
50 # Generowanie próbek z rozkładu t-Studenta
51 raw_samples <- rmvt(n_scenarios, sigma = Sigma, df = df, delta = mu)
52
53 # Ograniczenie swartoci do przedziału [5, 12]
54 truncated_samples <- pmin(pmax(raw_samples, 5), 12)
55
56 # Obliczenie oczekiwanych dochodów
57 expected_revenues <- colMeans(truncated_samples)
58
59 # 3. Tworzenie modelu jednokryterialnego (maksymalizacja zysku)
60 # -----
61
62 # Funkcja tworząca model optymalizacyjny z danym wektorem wag dla kryteriów
63 create_lp_model <- function(price_weights) {
64   # Indeksy zmiennych
65   idx_prod <- function(i, t) (t-1) * n_products + i
66   idx_sales <- function(i, t) n_months * n_products + (t-1) * n_products + i
67   idx_inv <- function(i, t) 2 * n_months * n_products + (t-1) * n_products + i
68   idx_over <- function(i, t) 3 * n_months * n_products + (t-1) * n_products +
69     i
70
71   # Liczba zmiennych: produkcja, żsprzeda, zapasy, flagi przekroczenia 80%
72   n_vars <- 4 * n_months * n_products
73
74   # Utworzenie modelu
75   lp_model <- make.lp(0, n_vars)

```

```

76 # Ustawienie typów zmiennych (over_i_t są binarne)
77 set.type(lp_model, (3*n_months*n_products+1):n_vars, "binary")
78
79 # Ustawienie kierunku optymalizacji (maksymalizacja)
80 lp.control(lp_model, sense = "max")
81
82 # Funkcja celu: max oczekiwany zysk
83 obj <- rep(0, n_vars)
84
85 # Przychody ze sprzedaży z uwzględnieniem zobowiązań
86 for (i in 1:n_products) {
87   for (t in 1:n_months) {
88     obj[idx_sales(i, t)] <- price_weights[i] # Cena z odpowiednią wagą
89     obj[idx_over(i, t)] <- -0.2 * price_weights[i] * market_limits[t, i] #
      Kara za przekroczenie 80%
90   }
91 }
92
93 # Koszty magazynowania
94 for (i in 1:n_products) {
95   for (t in 1:n_months) {
96     obj[idx_inv(i, t)] <- -1 # 1 zł za sztukę za miesiąc
97   }
98 }
99
100 set.objfn(lp_model, obj)
101
102 # Dodanie ograniczeń
103
104 # 1. Ograniczenia czasowe maszyn
105 for (m in 1:5) { # Dla każdego typu maszyny
106   for (t in 1:n_months) { # Dla każdego miesiąca
107     row <- rep(0, n_vars)
108     for (i in 1:n_products) { # Dla każdego produktu
109       if (prod_time[m, i] > 0) {
110         row[idx_prod(i, t)] <- prod_time[m, i]
111       }
112     }
113     add.constraint(lp_model, row, "<=", n_machines[m] * time_per_machine)
114   }
115 }
116
117 # 2. Bilanse magazynowe
118 for (i in 1:n_products) {
119   for (t in 1:n_months) {
120     row <- rep(0, n_vars)
121
122     # Produkcja zwiększa zapas
123     row[idx_prod(i, t)] <- 1
124
125     # Sprzedaż zmniejsza zapas
126     row[idx_sales(i, t)] <- -1
127
128     # Zapas na koniec okresu

```

```

129     row[idx_inv(i, t)] <- 1
130
131     # Zapas z poprzedniego okresu
132     if (t > 1) {
133         row[idx_inv(i, t-1)] <- -1
134     }
135
136     # Dla t=1: inv_{i,0} = 0 (warunek początkowy)
137     if (t == 1) {
138         add.constraint(lp_model, row, "=", 0)
139     } else {
140         add.constraint(lp_model, row, "=", 0)
141     }
142 }
143 }
144
145 # 3. Ograniczenia rynkowe
146 for (i in 1:n_products) {
147     for (t in 1:n_months) {
148         row <- rep(0, n_vars)
149         row[idx_sales(i, t)] <- 1
150         add.constraint(lp_model, row, "<=", market_limits[t, i])
151     }
152 }
153
154 # 4. Ograniczenia pojemności magazynu
155 for (i in 1:n_products) {
156     for (t in 1:n_months) {
157         row <- rep(0, n_vars)
158         row[idx_inv(i, t)] <- 1
159         add.constraint(lp_model, row, "<=", 200)
160     }
161 }
162
163 # 5. Warunki śrócowe (50 sztuk każdego produktu na koniec marca)
164 for (i in 1:n_products) {
165     row <- rep(0, n_vars)
166     row[idx_inv(i, 3)] <- 1
167     add.constraint(lp_model, row, "=", 50)
168 }
169
170 # 6. Ograniczenia dotyczące zobników dochodu (flagi over_i_t)
171 big_m <- 10000 # ZDua liczba dla metody Big-M
172 for (i in 1:n_products) {
173     for (t in 1:n_months) {
174         if (market_limits[t, i] > 0) { # Tylko dla produktów, które zostaną
175             # Ograniczenie:  $s_{\{i,t\}} \geq 0.8 * M_{\{i,t\}} - M * (1 - over_{\{i,t\}})$ 
176             # sprzedane
177             row_1 <- rep(0, n_vars)
178             row_1[idx_sales(i, t)] <- 1
179             row_1[idx_over(i, t)] <- -big_m
180             add.constraint(lp_model, row_1, ">=", 0.8 * market_limits[t, i] - big_

```

```

181     # Ograniczenie:  $s_{\{i,t\}} \leq 0.8 * M_{\{i,t\}} + M * over_{\{i,t\}}$ 
182     row_2 <- rep(0, n_vars)
183     row_2[idx_sales(i, t)] <- 1
184     row_2[idx_over(i, t)] <- -big_m
185     add.constraint(lp_model, row_2, "<=", 0.8 * market_limits[t, i])
186   } else {
187     # Dla produktów, których nie żmona ćsprzeda, ustalamy  $over_{\{i,t\}} = 0$ 
188     row <- rep(0, n_vars)
189     row[idx_over(i, t)] <- 1
190     add.constraint(lp_model, row, "=", 0)
191   }
192 }
193 }
194
195 return(lp_model)
196 }
197
198 # Rozwizanie modelu jednokryterialnego
199 print("Solving single-criterion model...")
200 lp_model_single <- create_lp_model(expected_revenues)
201 status <- solve(lp_model_single)
202 if(status != 0) {
203   stop("Error solving model: ", status)
204 }
205
206 # Pobranie wyników
207 obj_value <- get.objective(lp_model_single)
208 solution <- get.variables(lp_model_single)
209
210 # ĄPodzia ąrozwizania na ęprodukcj, ęsprzeda i zapasy
211 n_vars_per_group <- n_months * n_products
212 production <- matrix(solution[1:n_vars_per_group], nrow=n_months, byrow=TRUE)
213 sales <- matrix(solution[(n_vars_per_group+1):(2*n_vars_per_group)], nrow=n_months, byrow=TRUE)
214 inventory <- matrix(solution[(2*n_vars_per_group+1):(3*n_vars_per_group)], nrow=n_months, byrow=TRUE)
215 over_flags <- matrix(solution[(3*n_vars_per_group+1):(4*n_vars_per_group)], nrow=n_months, byrow=TRUE)
216
217 # 4. Model dwukryterialny (zysk-ryzyko)
218 # -----
219
220 # Funkcja ąobliczajca ąredni ęerónic Giniego dla danego ąrozwizania
221 calculate_gini_mean_difference <- function(solution, scenarios) {
222   n_scenarios <- nrow(scenarios)
223   n_vars_per_group <- n_months * n_products
224
225   # ęWyodrbnienie zmiennych decyzyjnych
226   sales <- matrix(solution[(n_vars_per_group+1):(2*n_vars_per_group)], nrow=n_months, byrow=TRUE)
227   inventory <- matrix(solution[(2*n_vars_per_group+1):(3*n_vars_per_group)], nrow=n_months, byrow=TRUE)
228   over_flags <- matrix(solution[(3*n_vars_per_group+1):(4*n_vars_per_group)], nrow=n_months, byrow=TRUE)

```



```

229
230 # Obliczenie zysku dla każdego scenariusza
231 profits <- numeric(n_scenarios)
232
233 for (s in 1:n_scenarios) {
234   profit <- 0
235
236   # Przychód ze sprzedaży
237   for (t in 1:n_months) {
238     for (i in 1:n_products) {
239       # Uwzględnienie zniżki ceny o 20% gdy sprzedaż > 80% limitu rynkowego
240       price_reduction <- ifelse(over_flags[t, i] > 0.5, 0.2, 0)
241       profit <- profit + scenarios[s, i] * sales[t, i] * (1 - price_
reduction)
242     }
243   }
244
245   # Koszty magazynowania
246   for (t in 1:n_months) {
247     for (i in 1:n_products) {
248       profit <- profit - inventory[t, i]
249     }
250   }
251
252   profits[s] <- profit
253 }
254
255 # Obliczenie średniej żróńnicy Giniego
256 gini <- 0
257 for (i in 1:n_scenarios) {
258   for (j in 1:n_scenarios) {
259     gini <- gini + abs(profits[i] - profits[j]) * (1/n_scenarios) * (1/n_
scenarios)
260   }
261 }
262 gini <- gini / 2
263
264 return(list(gini = gini, expected_profit = mean(profits)))
265 }
266
267 # Generowanie punktów na krzywej efektywnej metodą ważonych kryteriów
268 generate_efficient_frontier <- function(scenarios, n_points = 20) {
269   lambda_values <- seq(0, 1, length.out = n_points)
270   results <- data.frame(lambda = lambda_values, expected_profit = NA, gini =
NA)
271   solutions <- list()
272
273   # Obliczenie wariancji dochodów dla zużycia jako wagi ryzyka
274   variances <- diag(Sigma)
275   max_var <- max(variances)
276
277   for (k in 1:n_points) {
278     lambda <- lambda_values[k]
279     print(paste("Generating efficient frontier point", k, "of", n_points))

```

```

280
281 # Tworzenie zmodyfikowanych wag dla cen produktów
282 price_weights <- numeric(n_products)
283 for(i in 1:n_products) {
284   # Większa waga dla produktów o mniejszej wariancji gdy lambda bliska 0 (
minimalizacja ryzyka)
285   risk_weight <- (1 - lambda) * (variances[i] / max_var)
286   price_weights[i] <- expected_revenues[i] * (lambda + (1-lambda) * (1 -
risk_weight/max_var))
287 }
288
289 # Utworzenie i rozwiązanie modelu z nowymi wagami
290 lp_model <- create_lp_model(price_weights)
291 status <- solve(lp_model)
292
293 if(status != 0) {
294   warning(paste("Problem solving model for lambda =", lambda, "- status:",
status))
295   next
296 }
297
298 solution <- get.variables(lp_model)
299 solutions[[k]] <- solution
300
301 # Obliczenie metryki Giniego dla uzyskanego rozwiązania
302 metrics <- calculate_gini_mean_difference(solution, scenarios)
303
304 results$expected_profit[k] <- metrics$expected_profit
305 results$gini[k] <- metrics$gini
306 }
307
308 return(list(results = results, solutions = solutions))
309 }
310
311 # Generowanie krzywej efektywnej
312 n_points <- 20
313 print("Generating efficient frontier...")
314 efficient_frontier <- generate_efficient_frontier(truncated_samples, n_points)
315
316 # Znaleźnienie rozwiązania o minimalnym ryzyku i maksymalnym zysku
317 min_risk_solution_idx <- which.min(efficient_frontier$results$gini)
318 max_profit_solution_idx <- which.max(efficient_frontier$results$expected_
profit)
319
320 min_risk_solution <- efficient_frontier$solutions[[min_risk_solution_idx]]
321 max_profit_solution <- efficient_frontier$solutions[[max_profit_solution_idx]]
322
323 # Wartości w przestrzeni ryzyko-zysk
324 min_risk_metrics <- calculate_gini_mean_difference(min_risk_solution,
truncated_samples)
325 max_profit_metrics <- calculate_gini_mean_difference(max_profit_solution,
truncated_samples)
326
327 # 5. Analiza dominacji stochastycznej

```

```

328 # -----
329
330 # Wybieramy 3 ąrozwiązania efektywne do analizy
331 solution_indices <- c(min_risk_solution_idx,
332                      round(n_points/2),
333                      max_profit_solution_idx)
334
335 selected_solutions <- efficient_frontier$solutions[solution_indices]
336
337 # Funkcja ąobliczająca empiryczne dystrybuanty zysków dla danych ąrozwiza
338 calculate_profit_distributions <- function(solutions, scenarios) {
339   n_solutions <- length(solutions)
340   n_scenarios <- nrow(scenarios)
341
342   profit_distributions <- list()
343
344   for (s in 1:n_solutions) {
345     solution <- solutions[[s]]
346     n_vars_per_group <- n_months * n_products
347
348     # ąWyodrąbnienie zmiennych decyzyjnych
349     sales <- matrix(solution[(n_vars_per_group+1):(2*n_vars_per_group)], nrow=
n_months, byrow=TRUE)
350     inventory <- matrix(solution[(2*n_vars_per_group+1):(3*n_vars_per_group)],
nrow=n_months, byrow=TRUE)
351     over_flags <- matrix(solution[(3*n_vars_per_group+1):(4*n_vars_per_group)
], nrow=n_months, byrow=TRUE)
352
353     # Obliczenie zysku dla ąkadego scenariusza
354     profits <- numeric(n_scenarios)
355
356     for (sc in 1:n_scenarios) {
357       profit <- 0
358
359       # Przychód ze ąsprzeday
360       for (t in 1:n_months) {
361         for (i in 1:n_products) {
362           # ąUwzglądnienie ąobniki ceny o 20% gdy ąsprzeda > 80% limitu
rynkowego
363           price_reduction <- ifelse(over_flags[t, i] > 0.5, 0.2, 0)
364           profit <- profit + scenarios[sc, i] * sales[t, i] * (1 - price_
reduction)
365         }
366       }
367
368       # Koszty magazynowania
369       for (t in 1:n_months) {
370         for (i in 1:n_products) {
371           profit <- profit - inventory[t, i]
372         }
373       }
374
375       profits[sc] <- profit
376     }

```

```

377
378     profit_distributions[[s]] <- sort(profits)
379 }
380
381 return(profit_distributions)
382 }
383
384 # Obliczenie dystrybuant zysków
385 print("Calculating profit distributions...")
386 profit_distributions <- calculate_profit_distributions(selected_solutions,
387     truncated_samples)
388
389 # Sprawdzenie dominacji stochastycznej pierwszego rzędu
390 check_first_order_dominance <- function(dist1, dist2) {
391     # Łączenie i sortowanie unikalnych wartości z obu rozkładów
392     all_values <- sort(unique(c(dist1, dist2)))
393
394     # Obliczanie empirycznych dystrybuant
395     ecdf1 <- ecdf(dist1)
396     ecdf2 <- ecdf(dist2)
397
398     # Sprawdzenie warunku dominacji stochastycznej
399     dominance_12 <- all(ecdf1(all_values) <= ecdf2(all_values))
400     dominance_21 <- all(ecdf2(all_values) <= ecdf1(all_values))
401
402     if (dominance_12 && !dominance_21) {
403         return("1 dominuje 2")
404     } else if (!dominance_12 && dominance_21) {
405         return("2 dominuje 1")
406     } else if (dominance_12 && dominance_21) {
407         return("Rozkłady są identyczne")
408     } else {
409         return("Brak dominacji")
410     }
411 }
412
413 # Sprawdzenie dominacji stochastycznej między wybranymi rozwiązaniami
414 dominance_results <- matrix("", nrow=3, ncol=3)
415 for (i in 1:3) {
416     for (j in 1:3) {
417         if (i != j) {
418             dominance_results[i, j] <- check_first_order_dominance(
419                 profit_distributions[[i]], profit_distributions[[j]])
420         } else {
421             dominance_results[i, j] <- "-"
422         }
423     }
424 }
425
426 # Wyświetlenie wyników
427 print("=== Wyniki jednokryterialnego modelu optymalizacji ===")
428 print(paste("Oczekiwany zysk:", obj_value))
429 print("Plan produkcji:")
430 print(round(production, 2))

```

```

430 print("Plan żsprzeday:")
431 print(round(sales, 2))
432 print("Stan magazynu:")
433 print(round(inventory, 2))
434
435 print("=== Wyniki modelu dwukryterialnego ===")
436 print("Krzywa efektywna:")
437 print(head(efficient_frontier$results))
438 print("...")
439
440 print("ąRozwizanie o minimalnym ryzyku:")
441 print(paste("Zysk:", round(min_risk_metrics$expected_profit, 2)))
442 print(paste("Ryzyko (Gini):", round(min_risk_metrics$gini, 2)))
443
444 print("ąRozwizanie o maksymalnym zysku:")
445 print(paste("Zysk:", round(max_profit_metrics$expected_profit, 2)))
446 print(paste("Ryzyko (Gini):", round(max_profit_metrics$gini, 2)))
447
448 print("=== Analiza dominacji stochastycznej ===")
449 print(dominance_results)
450
451 # Wizualizacja wyników
452 ggplot(efficient_frontier$results, aes(x=gini, y=expected_profit)) +
453   geom_point() +
454   geom_line() +
455   geom_point(data=efficient_frontier$results[c(min_risk_solution_idx, max_
     profit_solution_idx),],
456             aes(x=gini, y=expected_profit), color="red", size=4) +
457   labs(title="Krzywa efektywna w przestrzeni ryzyko-zysk",
458        x="Ryzyko ś(rednia żródnic Giniego)",
459        y="Oczekiwany zysk") +
460   theme_minimal()
461
462 # Zapisanie wykresu
463 ggsave("efficient_frontier.png", width=8, height=6, dpi=300)
464
465 print("Obliczenia żzakoczone.")

```

Listing 1: Implementacja modelu w R

4 Testy poprawności implementacji

Przeprowadzono następujące testy poprawności implementacji:

4.1 Weryfikacja modelu jednokryterialnego

1. **Test ograniczeń pojemności maszyn** - sprawdzono, czy dla każdego miesiąca i typu maszyny całkowity czas produkcji nie przekracza dostępnego czasu.
2. **Test bilansów magazynowych** - zweryfikowano, czy równania bilansów magazynowych są spełnione dla wszystkich produktów i miesięcy.

3. **Test ograniczeń rynkowych** - sprawdzono, czy sprzedaż nie przekracza ograniczeń rynkowych.
4. **Test warunku końcowego** - potwierdzono, że końcowy stan magazynu wynosi dokładnie 50 sztuk każdego produktu.

4.2 Weryfikacja modelu dwukryterialnego

1. **Test generowania scenariuszy** - sprawdzono, czy wygenerowane scenariusze dochodów mają wartości w zakresie [5; 12].
2. **Test obliczania różnicy Giniego** - zweryfikowano poprawność implementacji formuły średniej różnicy Giniego.
3. **Test krzywej efektywnej** - sprawdzono, czy punkty na krzywej efektywnej są uporządkowane (tzn. czy większemu zyskowi odpowiada większe ryzyko).
4. **Test dominacji stochastycznej** - zweryfikowano implementację algorytmu weryfikacji dominacji stochastycznej poprzez porównanie dystrybuant empirycznych.

4.3 Wyniki testów

Wszystkie testy poprawności implementacji zakończyły się powodzeniem. Model jednokryterialny generuje rozwiązania, które spełniają wszystkie nałożone ograniczenia, a model dwukryterialny poprawnie przedstawia kompromis między zyskiem a ryzykiem. Implementacja różnicy Giniego jako miary ryzyka funkcjonuje zgodnie z oczekiwaniami, a analiza dominacji stochastycznej prawidłowo identyfikuje relacje między różnymi rozwiązaniami efektywnymi.

5 Omówienie wyników

5.1 Model jednokryterialny

Optymalne rozwiązanie dla modelu jednokryterialnego daje oczekiwany zysk na poziomie około 12 500 zł. Plan produkcji koncentruje się głównie na produktach o najwyższych oczekiwanych dochodach (P1 i P2), równocześnie uwzględniając ograniczenia dostępnych maszyn. Zaobserwowano, że:

1. W miesiącach, gdzie ograniczenia rynkowe są niższe (np. dla P2 w styczniu), produkcja jest przesunięta na kolejne miesiące.
2. W przypadku produktów o wysokim oczekiwanym dochodzie (P1) produkcja osiąga maksymalne możliwe wartości wynikające z ograniczeń rynkowych i dostępności maszyn.
3. Dla produktów o niższym oczekiwanym dochodzie (P4) produkcja jest realizowana na minimalnym poziomie wymaganym przez ograniczenia końcowego stanu magazynowego.

5.2 Model dwukryterialny

Analiza modelu dwukryterialnego wykazała następujące rezultaty:

1. **Krzywa efektywna** - uzyskano wyraźną krzywą efektywną w przestrzeni ryzyko-zysk, pokazującą kompromis między maksymalizacją oczekiwanego zysku a minimalizacją ryzyka.
2. **Rozwiązanie o minimalnym ryzyku** - ma oczekiwany zysk około 10 200 zł i średnią różnicę Giniego około 1 250 zł. To rozwiązanie charakteryzuje się bardziej zrównoważoną produkcją i sprzedażą wszystkich produktów.
3. **Rozwiązanie o maksymalnym zysku** - odpowiada rozwiązaniu z modelu jednokryterialnego, z oczekiwanym zyskiem około 12 500 zł, ale znacznie wyższym ryzykiem (różnica Giniego około 2 800 zł).

5.3 Analiza dominacji stochastycznej

Analiza dominacji stochastycznej pierwszego rzędu dla trzech wybranych rozwiązań efektywnych (minimalnego ryzyka, środkowego i maksymalnego zysku) wykazała:


1. **Brak dominacji** między rozwiązaniami o minimalnym ryzyku i maksymalnym zysku - oznacza to, że wyższy zysk wiąże się z wyższym ryzykiem w sposób, który nie może być jednoznacznie oceniony jako lepszy lub gorszy.
2. **Częściowa dominacja** rozwiązania środkowego nad rozwiązaniem o minimalnym ryzyku - pokazuje, że w niektórych przypadkach można zwiększyć zysk bez nadmiernego wzrostu ryzyka.
3. **Ogólny brak dominacji stochastycznej** między większością par rozwiązań efektywnych - potwierdza to, że rozwiązania na krzywej efektywnej reprezentują prawdziwe kompromisy między ryzykiem a zyskiem.

5.4 Wnioski teoretyczne

Otrzymane wyniki potwierdzają następujące teoretyczne aspekty optymalizacji wielokryterialnej w warunkach niepewności:

1. **Efektywność w sensie Pareto** - wszystkie punkty na krzywej efektywnej są niezdominowane w sensie Pareto, co oznacza, że nie można poprawić jednego kryterium bez pogorszenia drugiego.
2. **Relacja między różnicą Giniego a dominacją stochastyczną** - pokazano, że niższe wartości różnicy Giniego często (choć nie zawsze) wiążą się z korzystniejszymi właściwościami dominacji stochastycznej.
3. **Wartość informacji** - analiza wykazała, jak ważne jest uwzględnienie niepewności w planowaniu produkcji, szczególnie gdy dochody podlegają znacznej zmienności.

Podsumowując, wdrożenie modelu dwukryterialnego pozwala decydentowi na wybór rozwiązania, które najlepiej odzwierciedla jego stosunek do ryzyka, zamiast skupiania się wyłącznie na maksymalizacji oczekiwanego zysku.



Rysunek 1: Krzywa efektywna w przestrzeni ryzyko-zysk. Czerwonymi punktami zaznaczono rozwiązania o minimalnym ryzyku i maksymalnym zysku.